

L'IAG pour chefs de projets, analystes, développeurs et architectes SI

Redha Moulla

Paris, 10 - 11 septembre 2026

Plan de la formation

- Qu'est-ce que l'intelligence artificielle ?
- Éléments de machine learning et de deep learning
- IA générative
- Large Language Models (LLM)
- Les bonnes pratiques de prompting
- Les RAG et les Agents
- L'IAG dans le cycle de développement logiciel
- Enjeux éthique, de sécurité et de conformité de l'IAG

Qu'est-ce que l'intelligence artificielle ?

Définition littérale de l'intelligence artificielle

1. Intelligence

Ensemble des fonctions mentales ayant pour objet la connaissance conceptuelle et relationnelle.

- Larousse

2. Artificielle

Qui est produit de l'activité humaine (opposé à la nature).

- Larousse

Qu'est-ce que l'intelligence ?

La notion d'intelligence recouvre plusieurs facultés cognitives :

- ➊ **Raisonnement** : La capacité à résoudre des problèmes et à faire des déductions logiques.
- ➋ **Apprentissage** : L'aptitude à acquérir de nouvelles connaissances et à s'améliorer grâce à l'expérience.
- ➌ **Perception** : La compétence pour reconnaître et interpréter les stimuli sensoriels.
- ➍ **Compréhension** : L'habileté à saisir le sens et l'importance de divers concepts et situations.
- ➎ **Mémorisation** : La faculté de stocker et de rappeler des informations.
- ➏ **Créativité** : Le pouvoir d'inventer ou de produire de nouvelles idées, de l'originalité dans la pensée.

Mais est-ce que l'intelligence est réductible à des facultés mesurables ?

Article

AI Magazine Volume 27 Number 4 (2006) © AAAI

A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence

August 31, 1955

John McCarthy, Marvin L. Minsky,
Nathaniel Rochester,
and Claude E. Shannon

■ The 1956 Dartmouth summer research project on artificial intelligence was initiated by this August 31, 1955 proposal, authored by John McCarthy, Marvin Minsky, Nathaniel Rochester, and Claude Shannon. The original typescript consisted of 17 pages plus a table page. Copies of the typescript are housed in the archives at Dartmouth College and Stanford University. The first 3 pages state the proposal, and the remaining pages give qualitative descriptions of the work, along with the short autobiographical statements of the proposers.

We propose that a 2-month, 10-man study of artificial intelligence be carried out during the summer of 1956 at Dartmouth College in Hanover, New Hampshire. The study is to proceed on the basis of the conjecture that every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it. An attempt will be made to find how to make machines use lan-

guage, form abstractions and concepts, solve kinds of problems now reserved for humans, and improve themselves. We think that a significant advance can be made in one or more of these problems if a carefully selected group of scientists work on it together for a summer.

The following are some aspects of the artificial intelligence problem:

1. **Automatic Computers**
If a machine can do a job, then an automatic calculator can be programmed to simulate the machine. The speed and memory capacities of present computers may be insufficient to simulate many of the higher functions of the human brain, but the major obstacle is not lack of machine capacity, but our inability to write programs taking full advantage of what we have.
2. **How Can a Computer be Programmed to Use a Language**
It may be speculated that a large part of human thought consists of manipulating words according to rules of reasoning and rules of computation. From this point of view, forming a generalization consists of admitting a new

12 AI MAGAZINE

"We propose that a 2-month, 10-man study of artificial intelligence be carried out during the summer of 1956 at Dartmouth College in Hanover, New Hampshire. The study is to proceed on the basis of the conjecture that every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it. An attempt will be made to find how to make machines use language, form abstractions and concepts, solve kinds of problems now reserved for humans, and improve themselves. We think that a significant advance can be made in one or more of these problems if a carefully selected group of scientists work on it together for a summer."

L'intelligence artificielle selon John McCarthy

“It is the science and engineering of making intelligent machines, especially intelligent computer programs. It is related to the similar task of using computers to understand human intelligence, but AI does not have to confine itself to methods that are biologically observable.”

— John McCarthy

Le Test de Turing


Le Test de Turing, développé par Alan Turing en 1950, est une tentative de mesurer l'intelligence d'une machine, plus précisément de la faculté d'une machine à penser. Cette dernière n'étant pas si évidente à mesurer, le test substitue finalement à la faculté de penser celle de traiter le langage naturel comme un humain.

Les points clés du Test de Turing sont :

- Un interrogateur humain engage une conversation avec un humain et une machine, chacun étant caché de la vue de l'interrogateur.
- Si l'interrogateur ne peut pas déterminer systématiquement quelle est la machine, celle-ci est considérée comme ayant passé le test.
- Le test ne mesure pas la connaissance ou la capacité à être véridique, mais plutôt la capacité de reproduire le comportement humain.

Définition pragmatique de l'intelligence artificielle

Il s'agit d'un ensemble de techniques qui permettent à la machine d'accomplir des tâches qui requièrent traditionnellement une intelligence humaine.



IA forte vs IA faible

La distinction entre IA forte et IA faible se réfère à deux approches conceptuelles différentes dans le domaine de l'intelligence artificielle.

IA faible :

- Aussi connue sous le nom d'IA "étroite", elle est conçue pour effectuer des tâches spécifiques et ne possède pas de conscience.
- Les systèmes d'IA faible agissent et réagissent uniquement en fonction des instructions programmées et des algorithmes spécifiques.
- Exemples : assistants virtuels, systèmes de recommandation, reconnaissance vocale.

IA forte :

- Vise à créer des machines dotées de capacité de généralisation à l'image de l'intelligence humaine.
- L'IA forte serait capable d'apprendre, de raisonner, de résoudre des problèmes et de prendre des décisions indépendamment.
- À ce jour, l'IA forte reste un objectif à atteindre, qui fait l'objet de recherches intensives.

Éléments de machine learning et de deep learning

Qu'est-ce que la machine learning ?

L'apprentissage automatique est une branche de l'intelligence artificielle qui consiste à doter les machines de la capacité d'apprendre à partir de données sans que celles-ci ne soient explicitement programmées pour exécuter des tâches spécifiques.

- **IA discriminative** : Modélise la frontière entre les classes.
Exemples : classification de commentaires clients, routage de mails, credit scoring, diagnostic médical, etc.
- **IA générative** : modélise la distribution des données pour en générer de nouvelles.
Exemples : Génération de texte, d'images, de musique, etc.
- **Apprentissage par renforcement (Reinforcement Learning)** : apprend à prendre des décisions séquentielles dans un environnement.
L'agent n'imité pas ou ne classe pas, il agit pour maximiser une récompense.
Exemples : Algorithmes d'enchères, jeux vidéos, etc.

Machine learning discriminatif

L'apprentissage automatique est une branche de l'intelligence artificielle qui consiste à doter les machines de la capacité d'apprendre à partir de données sans que celles-ci ne soient explicitement programmées pour exécuter des tâches spécifiques.

Le machine learning englobe deux grandes familles d'apprentissage :

- **Supervisé** : Les algorithmes apprennent à partir de données étiquetées pour faire des prédictions ou classifications.
- **Non supervisé** : L'apprentissage est effectué sur des données non étiquetées pour trouver des structures cachées.

L'apprentissage supervisé

L'apprentissage supervisé consiste à apprendre un modèle qui associe une étiquette (*label*) à un ensemble de caractéristiques (*features*).

- **Inputs** : un jeu de données *annotées* pour entraîner le modèle.
 - Exemple : des textes (tweets, etc.) avec les *sentiment* associés, positifs ou négatifs.
- **Output** : une étiquette pour un point de donnée inconnu par le modèle.


L'apprentissage supervisé se décline lui-même en deux grandes familles :

- **La classification** : prédire une catégorie ou une classe.
 - Exemple : prédire l'étiquette d'une image (chat, chien, etc.), le sentiment associé à un texte, le centre d'intérêt d'un client à partir de ses commentaires, etc.
- **La régression** : prédire une valeur continue (un nombre réel typiquement).
 - Exemple : prédire le prix d'un appartement, la lifetime value d'un client, etc.

Régression linéaire simple


Soit un ensemble de n observations $x_1, x_2, \dots, x_n$ avec les labels correspondants $y_1, y_2, \dots, y_n$, on cherche le modèle linéaire qui ajuste le mieux ces données.

$$\hat{y} = \beta_0 + \beta_1 x$$




Minimisation du risque empirique 1/2

L'erreur de prédiction pour la i ième observation est : $e_i = y_i - \hat{y}_i$. où $\hat{y}_i = \beta_0 + \beta_1 x_i$.



Prédire le prix en fonction de la surface : inférence



L'apprentissage non supervisé


L'apprentissage non supervisé se réfère à l'utilisation de modèles d'apprentissage automatique pour identifier des patterns et des structures dans des données qui ne sont pas étiquetées.

Principales typologies de l'apprentissage non supervisé :

- **Clustering** : Regroupement de points de données similaires ensemble.
Exemple : segmentation de marché, regroupement social.
- **Détection d'anomalies** : Détecter des observations dont les caractéristiques sont inhabituelles par rapport à la majorité.


Clustering

Exemple de clustering : segmentation clients



Détection d'anomalies

Exemple de détection d'anomalies : fraude bancaire



Eléments de deep learning

Brève histoire du deep learning

1940-1980 : Fondations

- 1943 : Neurone artificiel (McCulloch & Pitts).
- 1986 : Rétropropagation (Rumelhart, Hinton, Williams).

1990-2000 : Hiver

- Manque de données et puissance de calcul.
- Progrès en théorie : SVM, modèles bayésiens.

2010-2020 : Renaissance

- 2012 : AlexNet révolutionne la vision par ordinateur.

Depuis 2020 : Multimodalité et LLM

- 2017 : Transformer, base des LLM.
- 2018 - 2020 : GPT-3, BERT.
- 2022 : ChatGPT...

Introduction aux réseaux de neurones


Définition : Les réseaux de neurones sont des modèles computationnels inspirés par le fonctionnement des neurones dans le cerveau humain. Ils sont capables d'apprendre des tâches complexes en modélisant des relations non linéaires entre les entrées et les sorties.

Caractéristiques :

- **Extraction automatique des features** : Capacité d'adaptation et d'extraction des features à partir des données sans programmation explicite.
- **Modélisation non linéaire** : Aptitude à capturer des relations complexes dans les données.
- **Modélisation en grande dimension** : Les modèles de deep learning sont particulièrement adaptés pour les données en grande dimension (images, texte, etc.).
- **Flexibilité** : Applicables à un large éventail de tâches et de typologies de données (images, langage naturel, données graphiques, etc.).

Extraction de features

Extraction de features en machine learning "classique"



Extraction de features en deep learning





Illustration d'un réseau de neurones classique



Neurone artificiel






Illustration des fonctions d'activation


Sigmoïde




Tanh



ReLU



ReLU paramétrique



La fonction SoftMax dans la classification dans la dernière couche

Le SoftMax transforme une liste de scores en **probabilités de classes**. C'est la dernière étape d'un modèle de classification multiclass.

Formule :

$$P(y_i) = \frac{e^{s_i}}{\sum_{j=1}^K e^{s_j}}$$

où s_i représente le score associé à la classe i , et K le nombre total de classes.

Exemple :

$$\text{Image} \rightarrow \begin{cases} \text{chat} : 0.80 \\ \text{chien} : 0.10 \\ \text{chameau} : 0.05 \\ \text{mouton} : 0.05 \end{cases}$$

→ Le modèle prédit la classe la plus probable (*chat*), tout en conservant une estimation pour les autres.

Intelligence artificielle générative (IAG)

Qu'est-ce que l'IA générative ?

Définition : L'intelligence artificielle générative (IAG) désigne les modèles capables de produire de nouvelles données (texte, image, son, code) qui imitent ou enrichissent des données existantes.

Idée clé : alors que le machine learning classique prédit, l'IAG crée.

Caractéristiques :

- Modèles entraînés sur des volumes massifs de données hétérogènes.
- Génération conditionnée par un prompt (instruction utilisateur).
- Capacité à généraliser au-delà des données vues pendant l'entraînement.

Deux grandes familles d'IA générative

IA générative pour le langage :


- Modèles de langage de grande taille (LLMs).
- Génération de texte cohérent et contextuel.
- Applications : chatbots, rédaction assistée, analyse de documents, génération de code.
- Exemples : GPT-4, Claude, LLaMA, Mistral.

IA générative pour les images :

- Modèles de diffusion et GANs.
- Création d'images réalistes ou stylisées à partir de descriptions textuelles.
- Applications : design, marketing, prototypage, art numérique.
- Exemples : DALL·E, Stable Diffusion, MidJourney.

Large Language Models (LLMs)

Fonctionnement des modèles génératifs



Le paramètre de température

Définition La température (T) contrôle le degré d'aléa dans les réponses générées. Elle agit sur la distribution de probabilité des mots avant l'échantillonnage.

Formule mathématique :

$$P(x_i) = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$$


- $T < 1 \rightarrow$ distribution plus concentrée, réponses plus prévisibles
- $T > 1 \rightarrow$ distribution plus plate, réponses plus variées et créatives

Autrement dit :

- Basse température $\rightarrow$ précision et cohérence.
- Haute température $\rightarrow$ imagination et diversité.

Illustration graphique de l'effet de la température

Effet de la température sur la distribution des probabilités



La tokénisation

Problème de départ : Les modèles de langage ne peuvent pas traiter directement du texte brut : les mots, les accents, la ponctuation et les variations sont trop nombreux (plusieurs millions de combinaisons possibles).

La tokénisation : Elle consiste à découper le texte en **unités réutilisables et limitées en nombre**, appelées *tokens*. Chaque token est ensuite représenté par un identifiant numérique que le modèle peut apprendre à prédire.

Intérêt de la tokénisation :

- Réduire la complexité du vocabulaire : on passe de millions de mots à quelques dizaines de milliers de tokens.
- Gérer les mots inconnus ou rares en les décomposant en sous-unités connues.
- Offrir une représentation numérique uniforme du langage, compatible avec les réseaux de neurones.

La composition des données d'entraînement des modèles

Principe général Les modèles de langage sont entraînés sur d'immenses corpus de texte — souvent plusieurs milliers de milliards de tokens — issus de sources très diverses pour couvrir la langue, les faits et les styles.

Sources typiques de données :

- **Web public** : pages web, articles, forums, Wikipédia (ex. Common Crawl).
- **Livres et documents** : œuvres littéraires, articles scientifiques, rapports techniques.
- **Données de code** : dépôts GitHub, notebooks, documentation technique.
- **Conversations et dialogues** : jeux de données de chat, discussions de forums, données annotées par des humains.
- **Données synthétiques** : textes générés par d'autres modèles pour enrichir certaines thématiques.

Équilibre recherché :

- Diversité linguistique et thématique (langues, registres, domaines).
- Qualité et cohérence (filtrage du spam, des doublons, des contenus toxiques).
- Représentation équilibrée entre langage courant, technique et conversationnel.

GPT-3

- Développé par OpenAI, publié en 2020.
- Modèle auto-régressif basé sur l'architecture Transformer.

Caractéristique	Valeur / Détail
Date	2020
Paramètres	175 milliards
Corpus d'entraînement	Environ 300 milliards de tokens
Contexte maximum	2048 tokens
Ressources GPU	Plusieurs centaines de GPU (type V100)
Coût d'entraînement (estim.)	4,6 M\$ à 12 M\$ (selon les sources)

- **Applications** : génération de texte, Q&R, résumé, traduction, assistance à la programmation.

Le few-shot learning

- Les grands modèles (comme GPT-3) peuvent réaliser des tâches **sans être explicitement réentraînés** dessus.
- Le principe repose sur **l'utilisation de quelques exemples** (exemples étiquetés) directement dans le prompt ou l'entrée.
- **Zero-shot** : aucune démonstration fournie, le modèle doit comprendre la tâche à partir de sa connaissance générale.
- **One-shot / Few-shot** : on inclut un nombre très réduit d'exemples (un ou quelques-uns) pour guider le modèle dans la résolution de la tâche.
- Exemple :

English: "cat" → French: "chat"

English: "house" → French: "maison"

English: "car" → French: "voiture"

English: "tree" → French:

ChatGPT

ChatGPT, développé par OpenAI, est un modèle de langage basé sur l'architecture GPT (Generative Pre-trained Transformer) optimisé pour comprendre et générer des dialogues naturels. L'entraînement de ChatGPT se décline selon les étapes

suivantes :

- ❶ **Pré-entraînement sur un corpus volumineux** : Comme GPT-3, ChatGPT est d'abord pré-entraîné sur un vaste ensemble de données textuelles, englobant un large éventail de la littérature disponible sur Internet, pour apprendre une compréhension générale du langage.
- ❷ **Fine-tuning supervisé** : Ensuite, ChatGPT est affiné sur des dialogues spécifiques pour améliorer ses compétences conversationnelles. Cette étape utilise des paires question-réponse et des conversations pour enseigner au modèle des structures de dialogue et des réponses contextuellement appropriées.
- ❸ **Reinforcement Learning from Human Feedback (RLHF)**: Utilisation de techniques de renforcement pour ajuster les réponses du modèle basées sur les préférences et les corrections fournies par des évaluateurs humains, raffinant davantage la pertinence et la naturalité des réponses.

LLMs propriétaires vs Open Source

● Modèles propriétaires


- ChatGPT, Claude, Gemini, Grok...
- Poids non disponibles au public.
- Performances élevées, accès limité par API payante
- Protection intellectuelle stricte (code non accessible)
- Support technique assuré, documentation avancée
- Dépendance aux fournisseurs et coûts potentiellement élevés

● Modèles open source


- Llama, Mistral, Gemma, DeepSeek, Qwen...
- Poids disponibles au public
- Transparence du code, flexibilité d'adaptation
- Performances parfois inférieures, mais amélioration continue
- Gratuit, mais coût de l'infrastructure à gérer
- Exposition aux failles potentielles de sécurité, support communautaire

Conclusion : Choisir entre contrôle, flexibilité et performances optimales.

Comparaison des performances des LLMs : benchmarks classiques



Evolution des performances des LLMs sur SWE-Bench



Introduction au prompting

Définition : Le prompting est l'art de formuler des instructions à un modèle de langage afin d'obtenir une réponse pertinente et de qualité.

Idée clé : La qualité de la sortie dépend fortement de la manière dont l'entrée est rédigée.

Enjeux :

- Obtenir des résultats précis et cohérents.
- Réduire les risques d'ambiguïtés et d'hallucinations.
- Adapter le style et le niveau de détail de la réponse.

Techniques de base du prompting

- **Prompt clair et explicite** : éviter les formulations vagues.
- **Contexte** : fournir des informations supplémentaires pour orienter le modèle.
- **Format attendu** : indiquer la structure de sortie souhaitée (liste, tableau, texte court).
- **Exemples** : montrer un ou plusieurs cas pour guider la génération.

Exemple : Au lieu de "C'est quoi le machine learning ?", écrire "Donne une explication détaillée du fonctionnement du machine learning, illustrée avec un exemple".

1. Le ton change la structure du raisonnement

Principe

Le ton du prompt influence non seulement le style, mais aussi la structure logique de la réponse.

Effets observés

- Ton calme et analytique : produit une écriture déductive et ordonnée, où le modèle explicite les causes et développe les idées avant de conclure.
- Ton urgent ou tendu : génère une écriture télégraphique, orientée vers l'action, avec phrases courtes et listes de décisions.

Exemples

« Explique posément, en suivant un raisonnement logique. » « Vite : résume-moi ce que je dois dire au client dans deux minutes. »

À retenir

Le ton est un levier cognitif : il modifie la manière dont le modèle raisonne avant même d'écrire.

2. Les métaphores encadrent la pensée

Principe

La métaphore impose un cadre de raisonnement : elle force le modèle à réencoder le concept dans une structure familière.

Effets observés

- Elle permet d'aborder des notions abstraites par transfert analogique.
- Elle structure naturellement la réponse selon les dimensions de la métaphore (par exemple : ingrédients, recettes, cuisson).

Exemples

« Explique le machine learning comme si c'était une cuisine. » « Explique l'optimisation comme une randonnée avec des étapes et des sommets. »

À retenir

La métaphore agit comme un cadre cognitif qui oriente la logique et le vocabulaire du texte.

3. Les rôles activistes des corpus latents

Principe

Attribuer un rôle au modèle sélectionne une manière de parler et de raisonner issue de son corpus.

Effets observés

- Historien : met l'accent sur la chronologie et les causes profondes.
- Ingénieur sceptique : insiste sur les hypothèses, les tests et les limites.
- Poète critique : privilégie les images, les tensions et le rythme.

Exemples

« Agis comme un historien en expliquant les causes profondes. » « Réponds comme un ingénieur qui doute de ses propres hypothèses. »

À retenir

Le rôle agit comme un filtre stylistique et culturel qui oriente la réponse sans en changer le fond.

4. La précision du contexte vaut plus que la longueur

Principe

Un contexte précis et incarné produit de meilleures réponses qu'une longue liste d'instructions abstraites.

Effets observés

- Le modèle comprend mieux la situation lorsqu'elle est ancrée dans un cadre concret.
- Les réponses deviennent plus pertinentes et plus naturelles.

Exemples

« Tu écris à ton supérieur, ton ferme mais respectueux, objectif : obtenir une validation avant 18 h. » « En 200 mots, identifie trois risques et formule une demande de décision. »

À retenir

Un cadre incarné aide le modèle à raisonner comme dans une situation réelle.

5. Les verbes d'action changent la dynamique

Principe

Le verbe choisi détermine le type de raisonnement attendu.

Effets observés

- Explique : logique de cause à effet.
- Montre : logique d'exemple et d'illustration.
- Révèle : logique d'enquête ou de découverte.

Exemples

« Explique en trois causes principales. » « Montre deux exemples concrets et un contre-exemple. » « Révèle l'élément caché qui change la conclusion. »

À retenir

Le verbe oriente la structure du texte et la nature du raisonnement.

6. Le silence comme outil

Principe

Ne pas tout préciser laisse au modèle une marge d'interprétation, propice à la créativité.

Effets observés

- Le modèle complète avec des régularités contextuelles, souvent pertinentes.
- Trop de contraintes bloque la pensée et conduit à des réponses formatées.

Exemples

« Donne trois options, dont une plus audacieuse, sans les justifier. » « Rédige un brouillon brut, sans titres, avec les idées clés uniquement. »

À retenir

Le vide agit comme un espace de respiration qui stimule la créativité.

7. Les émotions modulent l'énergie du contenu

Principe

Le ton émotionnel du prompt influence le rythme et la profondeur de la réponse.

Effets observés

- Colère : texte direct, tranchant, orienté vers la critique.
- Tristesse : rythme lent, ton grave, introspection.
- Joie : rythme rapide, style fluide et enthousiaste.
- Admiration : langage figuré et ample.

Exemples

« Sans détour, dis-moi ce qui ne va pas dans cette stratégie. » « Parle avec gravité des risques systémiques en trois points. »

À retenir

L'émotion structure le raisonnement en modulant l'énergie et la focalisation.

8. Le paradoxe pousse la nuance

Principe

Introduire une contradiction dans le prompt oblige le modèle à produire une réponse nuancée.

Effets observés

- Le modèle cherche un équilibre entre deux pôles logiques.
- Il produit une pensée dialectique plutôt qu'un simple commentaire.

Exemples

« Explique pourquoi l'IA est à la fois une menace et une promesse. » « Montre en quoi le progrès peut être à la fois un risque et une chance. »

À retenir

Le paradoxe favorise la nuance et la réflexion véritable.

1. Le prompt comme dispositif de situation

- Les modèles réagissent mieux à une situation incarnée qu'à une instruction abstraite. → Exemple : « Vous êtes face à un comité sceptique, vous devez défendre votre position. »
- L'efficacité vient d'un processus itératif : cadrer, ajuster, affiner le ton et la forme.
- Les consignes les plus performantes précisent l'objectif plutôt que les moyens.
→ Exemple : « Rédige un texte qui donne envie de s'inscrire à la formation. »

Un bon prompt crée un contexte de pensée, pas une suite d'ordres.

2. Créer un cadre ouvert mais dirigé

- Laisser une marge d'interprétation encourage la créativité sans perdre le contrôle. → Exemple : « Propose trois options, dont une plus audacieuse. »
- La reformulation est un outil d'ancrage : elle stabilise le style et le ton. → Exemple : « Conserve ce ton, mais rends le propos plus concret. »
- Les prompts dialectiques favorisent la nuance et la profondeur. → Exemple : « Expose les arguments pour et contre l'usage de l'IA générative. »

L'ouverture maîtrisée est plus féconde que la prescription exhaustive.

3. Soigner l'entrée du modèle

- La première phrase fixe le registre cognitif du texte. → « Agis comme... » crée un ton professionnel. → « Imagine que... » stimule la créativité. → « Explique-moi... » installe un registre analytique.
- Certains mots volontairement flous activent des régularités de style. → Exemple : « Écris un texte juste » conduit souvent à une écriture sobre et sincère.

Les premiers mots d'un prompt déterminent souvent la posture du modèle.

4. Guider la génération au fil du dialogue

- Les relances directionnelles (« Va plus loin », « Simplifie sans appauvrir ») orientent la production sans l'alourdir.
- Demander au modèle de se corriger déclenche une forme de métacognition.
→ Exemple : « Relis ta réponse comme un relecteur exigeant. Que modifierais-tu ? »
- Le feedback positif est plus structurant que la contrainte négative. → Il permet au modèle d'ajuster progressivement sa cohérence stylistique.

Le dialogue, bien conduit, devient un véritable apprentissage contextuel.

5. Dialoguer avec une voix, pas avec une machine

- Les modèles ne « obéissent » pas : ils estiment la suite la plus probable. → Il s'agit donc d'orienter plutôt que d'imposer.
- « Tu peux être incisif » produit souvent de meilleurs résultats que « Sois incisif ».
- Initier un ton puis le prolonger (« Continue dans le même style ») garantit la cohérence d'ensemble.
- Les LLMs sont des condensés de mémoire culturelle : plus le langage est humain, plus la réponse le sera.

Un prompt efficace s'adresse à une voix, pas à un programme.

6. Structurer le prompt : du zero-shot au few-shot

- **Zero-shot** : le modèle exécute la tâche uniquement à partir d'une consigne.
→ Adapté aux tâches simples ou familières. → Exemple : « Rédige un e-mail de relance professionnel pour un client inactif. »
- **Few-shot** : on fournit au modèle quelques exemples du comportement attendu avant la demande réelle. → Le modèle en déduit la structure, le ton et le registre à reproduire.
- **Chain-of-thought** : on invite le modèle à expliciter son raisonnement avant la conclusion. → Exemple : « Décris ton raisonnement étape par étape avant de proposer la recommandation finale. »

La structuration du prompt agit comme un guide cognitif : elle oriente la logique, la précision et la cohérence du résultat.

Modèles de raisonnement

Objectif : améliorer la capacité des LLMs à résoudre des problèmes complexes en rendant explicites les étapes de raisonnement.

Principe des *Chain-of-Thoughts* (CoT) :

- Décomposer une question en **étapes intermédiaires logiques**.
- Forcer le modèle à **“penser à voix haute”** avant de donner la réponse finale.
- Exemple : résoudre une équation, planifier une suite d'actions, raisonner sur des données tabulaires.

Méthodes d'entraînement :

- **Fine-tuning supervisé** sur des datasets annotés avec étapes de raisonnement.
- **Self-consistency** : générer plusieurs chaînes et agréger la réponse la plus fréquente/cohérente.
- **Distillation** : transférer les capacités de raisonnement d'un grand modèle vers un plus petit.

Agents basés sur les LLMs

Définition : un agent est un système qui exploite un LLM comme moteur de raisonnement et de décision, capable d'interagir avec des outils et un environnement externe.

Caractéristiques principales :

- **Boucle perception–action** : observe, raisonne, agit, et réévalue.
- **Accès à des outils** : API, bases de données, navigateurs, scripts.
- **Mémoire** : conserve l'historique et les connaissances pertinentes.
- **Planification** : décompose un objectif en sous-tâches exécutables.

Limites actuelles des LLMs : deux axes majeurs

1. Hallucinations

- Génération de contenus inexacts ou inventés, parfois avec une forte confiance.
- Difficulté à distinguer le vrai du plausible, surtout hors du domaine d'entraînement.
- Conséquences : risque de désinformation, perte de fiabilité, nécessité de vérification humaine.

2. Non-déterminisme

- Un même prompt peut produire plusieurs réponses différentes.
- Résultats sensibles à la température, au contexte ou à de légères variations de formulation.
- Enjeu pour la reproductibilité et le contrôle qualité des systèmes fondés sur les LLMs.


IAG dans le cycle de développement

L'IAG dans le cycle de vie logiciel

L'intelligence artificielle générative ne se limite pas à l'autocomplétion de code : elle peut s'intégrer à chaque étape du cycle de vie logiciel pour assister les équipes.

- **Conception** : clarification des besoins, spécifications, ébauches d'architecture.
- **Développement** : génération et refactor de code, assistance aux patterns.
- **Tests** : génération de tests unitaires et fonctionnels, détection de cas limites.
- **Intégration & CI/CD** : review automatique de PR, génération de changelog et documentation.
- **Déploiement** : notes de version, assistance à l'infrastructure-as-code.
- **Maintenance** : classification des tickets, suggestions de correctifs, documentation à partir du code.

IAG dans le cycle de vie logiciel



Conception et spécifications

Objectif : réduire l'ambiguïté et accélérer le passage du besoin métier à la solution technique.

- Transformer une *user story* en endpoints d'API (routes, verbes, schémas JSON).
- Générer une première ébauche d'architecture (services, flux, dépendances).
- Produire un glossaire ou des critères d'acceptation testables.

Exemple de prompt : « À partir de cette *user story*, propose les endpoints REST, les codes d'erreur et un schéma JSON pour POST /orders. »

Objectif : accélérer l'implémentation tout en améliorant la lisibilité et la maintenabilité.

- Génération de fonctions à partir d'une description en langage naturel.
- Refactor : extraction de sous-fonctions, renommage de variables, simplification de structures.
- Suggestions de design patterns adaptés au contexte.

Exemple : Avant : fonction monolithique de 80 lignes. Après : découpage en `validate()`, `transform()`, `persist()` avec docstrings et exceptions typées.

Objectif : améliorer la couverture et détecter les cas limites dès la phase de développement.

- Génération de tests unitaires directement à partir du code.
- Proposition de cas extrêmes : valeurs limites, erreurs réseau, formats inattendus.
- Création de scénarios fonctionnels dérivés des user stories.

Exemple de prompt : « *Voici la fonction `price(order)`. Génère 8 tests unitaires `pytest` couvrant remise, TVA, devise inconnue, quantité négative, seuils, valeur nulle.* »

Objectif : enrichir les pipelines d'intégration continue avec des capacités d'analyse et de génération.

- Review automatique de pull requests : détection de failles de sécurité, de duplications, de style incohérent.
- Génération automatique de tests complémentaires pour valider les commits.
- Production de documentation et de changelogs à partir des messages de commits.

Exemple : Un workflow GitHub Actions envoie le *diff* à un LLM, qui commente directement la PR avec ses suggestions.

Objectif : automatiser et simplifier les tâches de mise en production.

- Assistance à la rédaction de scripts *infrastructure-as-code* (Terraform, Ansible).
- Génération automatique des notes de version lisibles à partir des commits.
- Support aux équipes DevOps pour documenter et communiquer les changements.

Exemple : À partir de commits techniques, l'IAG rédige un changelog clair pour les utilisateurs finaux.

Objectif : accélérer la résolution de problèmes et réduire la dette technique.

- Classification automatique des tickets d'incidents par priorité et catégorie.
- Proposition de correctifs initiaux pour certains bugs.
- Génération de documentation à partir de code existant ou de logs.

Exemple : Un log d'erreur est soumis à l'IAG, qui propose un diagnostic et une piste de correction.

Points de vigilance lors de l'intégration de l'IA :

- **Qualité variable** : sorties parfois incomplètes ou erronées, besoin de supervision humaine.
- **Sécurité et confidentialité** : attention à l'envoi de code ou de données sensibles.
- **Coût et performance** : appels API facturés au token, temps de latence selon les modèles.
- **Dépendance technologique** : choix entre solutions cloud, open source locales ou hybrides.

Message clé : l'IA est un assistant puissant, mais elle ne remplace pas le rôle critique du développeur et de l'architecte.

Le contexte du dépôt doit rester court et stable

- Décrire l'architecture et les conventions durables.
- Donner les commandes de test et de validation.
- Indiquer les zones sensibles ou interdites.
- Renvoyer vers les documents détaillés.
- Éviter l'historique du projet et les longues procédures.

Exemple : AGENTS.md

- Architecture
- Conventions
- Commandes
- Contraintes
- Liens utiles

Principe

Le contexte permanent sert à orienter l'agent, pas à remplacer toute la documentation.

Économiser des tokens : garder un contexte utile

1

Charger à la demande

N'ouvrir que les fichiers nécessaires à la tâche en cours.

2

Résumer l'avancement

Conserver décisions, contraintes et points encore ouverts.

3

Sortir le détail

Placer exemples, références et procédures dans des fichiers dédiés.

À retenir

Moins de contexte améliore souvent le coût, la latence et l'attention portée aux contraintes importantes.

Optimiser le coût sans dégrader le résultat

Avant l'appel

- Définir un résultat attendu.
- Réduire le périmètre.
- Choisir le modèle adapté.

Pendant l'exécution

- Réutiliser les résultats stables.
- Éviter les boucles ouvertes.
- Borner le nombre d'essais.

Après l'appel

- Mesurer tokens et latence.
- Comparer coût et qualité.
- Capitaliser les bons patrons.

Règle pratique : réserver les modèles les plus coûteux aux tâches où leur gain de qualité est mesurable.

Isoler l'exécution et limiter les accès

Environnement contrôlé

- Conteneur ou espace de travail isolé.
- Dépendances et versions reproductibles.
- Données de test non sensibles.
- Accès réseau explicites.


Droits minimaux

- Lecture avant écriture.
- Secrets hors des prompts et des journaux.
- Confirmation pour les actions irréversibles.
- Identité technique dédiée si nécessaire.

Point de vigilance

Une consigne en langage naturel ne constitue pas une barrière de sécurité.

Automatiser les contrôles déterministes



- Le formateur, le linter, le compilateur et les tests donnent des verdicts reproductibles.
- L'agent peut corriger automatiquement tant que le nombre d'itérations reste borné.
- Les choix fonctionnels, architecturaux ou risqués restent soumis à une revue humaine.

Principe

Ne pas demander au modèle ce qu'un outil déterministe peut vérifier plus sûrement.

Revoir le résultat avant de fusionner

Vérifier le changement

- Le besoin est-il réellement couvert ?
- Le diff reste-t-il limité au périmètre demandé ?
- Les erreurs et cas limites sont-ils traités ?
- La solution respecte-t-elle l'architecture ?

Vérifier les preuves

- Les tests pertinents ont-ils été exécutés ?
- Les résultats sont-ils reproductibles ?
- Les risques résiduels sont-ils explicites ?
- La documentation utile est-elle mise à jour ?

Responsabilité : l'auteur ou le relecteur reste responsable du code fusionné, quelle que soit son origine.

À quoi sert un Skill ?

Sans Skill

L'utilisateur répète le rôle, les étapes, les outils, les contraintes et le format de sortie à chaque demande.

Avec un Skill

L'agent charge une procédure versionnée, réutilisable et spécialisée lorsque la tâche la déclenche.

Un Skill peut regrouper :

- des instructions de travail et des critères de qualité ;
- des scripts, modèles de fichiers ou exemples ;
- des règles indiquant quand l'utiliser et quand s'arrêter.

Idée clé

Un Skill transforme une bonne manière de travailler en capacité réutilisable par l'équipe.

Un Skill comprend des instructions et des ressources

Structure possible

```
mon-skill/  
  SKILL.md  
  scripts/  
  references/  
  templates/  
  examples/
```

SKILL.md objectif, déclencheurs, procédure et contrôles.

Scripts automatisations fiables et reproductibles.

Références documentation chargée seulement si nécessaire.

Modèles formats de sortie prêts à adapter.

Exemples cas représentatifs et résultats attendus.

Bonne pratique : garder le fichier principal court et orienter l'agent vers les ressources utiles à chaque étape.

Exemples de Skills dans un dépôt public

Qualité et maintenance

- revue de code et qualité ;
- refactorisation ;
- débogage systématique ;
- génération et analyse de tests.

Conception et livraison

- architecture logicielle ;
- conception d'API ;
- sécurité applicative ;
- documentation technique.

Dépôt d'exemples

github.com/addyosmani/agent-skills

Le dépôt sert de catalogue : chaque équipe doit adapter les procédures à son architecture, ses outils et son niveau de risque.

Le Skill code-review-and-quality

Ce qu'il organise

- lecture du contexte et du diff
- recherche de défauts concrets
- classement par gravité
- localisation des problèmes
- propositions de correction

Ce qu'il évite

- commentaires génériques
- préférences de style non justifiées
- conclusions sans preuve
- réécriture inutile de tout le code
- oubli du comportement attendu

L'équipe doit maintenir le Skill comme du code

- ➊ **Versionner** les instructions, scripts, modèles et exemples.
- ➋ **Relire** les changements qui modifient le comportement de l'agent.
- ➌ **Mesurer** la qualité, le coût, la latence et les échecs récurrents.
- ➍ **Retirer** les règles obsolètes et documenter les décisions importantes.

Gouvernance minimale

Un responsable identifié, des critères d'acceptation, un historique des versions et une procédure de retour arrière.

Point d'attention

Un Skill non maintenu peut diffuser rapidement une pratique obsolète à toute l'équipe.

Synthèse :

- L'IAG peut intervenir à chaque étape du cycle de vie logiciel.
- Elle augmente la productivité, améliore la documentation et renforce les tests.
- Elle exige des précautions (qualité, sécurité, gouvernance).

Ouverture :

- Quelle phase du cycle de vie tirerait le plus de bénéfice de l'IAG dans vos projets ?
- Quels freins organisationnels ou techniques voyez-vous à son adoption ?

IAG pour la gestion de projet

Usages de l'IAG en gestion de projet

L'IAG réduit le temps consacré à rechercher, reformuler et recopier l'information.

Préparer

Structurer un brief, un plan ou une première liste de risques.

Surveiller

Faire ressortir retards, blocages et incohérences dans le suivi.

Coordonner

Transformer réunions, demandes et décisions en actions suivies.

Communiquer

Produire une synthèse adaptée à chaque destinataire.

Les outils récents permettent aussi de créer des tâches, renseigner le suivi et déclencher des workflows.

Notes et transcription → Décisions suivies → Actions → Tâches

L'AG peut extraire

- les décisions effectivement prises
- les actions, responsables et échéances
- les questions encore ouvertes
- les risques ou dépendances évoqués.

Elle peut ensuite

- préparer le compte rendu
- créer ou compléter les tâches
- mettre à jour le journal des décisions
- publier une synthèse pour l'équipe.

Planification du projet

Informations fournies

- objectif et contexte
- livrables attendus
- contraintes connues
- calendrier et équipes
- documents existants.

Premier résultat proposé

- lots, tâches et jalons
- dépendances à examiner
- parties prenantes
- critères de réussite
- hypothèses et première liste de risques.

Reporting du projet

Questions posées au système

- Qu'est-ce qui a changé depuis le dernier comité ?
- Quels jalons sont menacés ?
- Quelles décisions sont attendues ?
- Pourquoi cette tâche est-elle bloquée ?
- Quels engagements ont été pris au client ?

Documents produits

- résumé exécutif
- état d'avancement détaillé
- liste des blocages
- ordre du jour du prochain comité
- message adapté à chaque destinataire.

Détection des risques

Signaux structurés

- tâches en retard
- dépendances bloquées
- charge ou délais incohérents
- absence de mise à jour
- multiplication des changements.

Signaux dans les échanges

- inquiétudes récurrentes
- décisions repoussées
- désaccords non résolus
- nouvelles contraintes
- engagements contradictoires.

L'IAG relie les informations et explique les signaux.

Les méthodes analytiques estiment une probabilité de retard, une dérive de coût ou une charge future à partir de données historiques.

Niveaux d'automatisation

- ➊ **Rédiger** : produire un compte rendu, un mail ou une synthèse.
- ➋ **Comprendre le projet** : rechercher dans les tâches, documents, échanges et décisions.
- ➌ **Mettre à jour** : créer des tâches, renseigner des champs, publier une synthèse ou router une demande.
- ➍ **Surveiller en continu** : repérer un écart et déclencher un workflow défini à l'avance.

Données du projet

Les informations utilisées proviennent des tâches, jalons, documents, décisions, risques et échanges associés au projet.

Les éléments les plus utiles sont :


- des tâches avec un état et un responsable
- des jalons et dépendances identifiés
- un journal des décisions
- des risques suivis et réévalués
- des documents accessibles avec des droits cohérents.

IAG pour les processus agiles

IAG et agilité : pourquoi

L'IAG peut accélérer le flux agile sans remplacer les rôles (PO, SM, devs).

- Réduire la charge cognitive : moins de tâches répétitives.
- Fluidifier la communication métier ↔ technique.
- Standardiser les artefacts agiles (stories, comptes rendus, doc).



Backlog et user stories

Objectif : produire des stories claires et actionnables.

- Génération ou reformulation des user stories (format *en tant que...* *je veux...* *afin de...*).
- Extraction d'acceptance criteria à partir de notes ou tickets.
- Suggestion de priorisation (valeur, risque, dépendances) à challenger par l'équipe.

Exemple : notes de réunion → 3 stories + 6 critères d'acceptation.

Planification de sprint

Objectif : accélérer la préparation sans figer la décision humaine.

- Proposition de plan de sprint à partir du backlog et de la vélocité historique.
- Décomposition automatique d'une story en sous-tâches techniques.
- Estimation initiale (story points) à discuter en poker planning.

Remarque : la planification finale reste une décision d'équipe.

Daily et rétrospectives

Objectif : rendre visibles décisions et blocages.

- Synthèse des points d'hier/aujourd'hui, risques et dépendances.
- Génération de compte rendu de daily et suivi des actions.
- Rétro assistée : agrégation des faits, top/flop, actions d'amélioration proposées.

Exemple : transcript de rétro → plan d'actions priorisé.

Objectif : documenter au fil de l'eau sans friction.

- Mise à jour de la documentation à partir des merges et releases.
- Rédaction de *definition of done*, checklists de qualité, guides internes.
- Adaptation multi-publics : résumé pour direction, détail pour dev/ops, pas-à-pas utilisateur.

Exemple : chatbot interne entraîné sur la doc projet et les règles agiles.

Bonnes pratiques et limites

Principes :

- L'IAG assiste, elle ne décide pas ; validation humaine systématique.
- Confidentialité : ne pas envoyer d'infos sensibles ; utiliser un proxy ou un modèle local si besoin.
- Transparence : tracer prompts, versions et décisions générées.

Petits pas :

- Commencer par la reformulation de stories et les comptes rendus.
- Étendre à la planification et à la doc si l'équipe est convaincue.

Enjeux éthiques, sécurité et conformité de l'IA

Pourquoi parler d'éthique et de sécurité ?

L'intelligence artificielle générative ne pose pas seulement des défis techniques : elle soulève des enjeux critiques pour l'entreprise.

- **Sécurité** : risques de fuite de secrets ou d'attaques via les prompts.
- **Confidentialité** : conformité au RGPD, respect des données sensibles.
- **Propriété intellectuelle** : **propriété des données d'entraînement et du contenu généré par l'IA.**
- **Éthique** : biais, équité, responsabilité dans l'usage.

Message clé : l'adoption de l'IA doit être accompagnée d'une gouvernance adaptée.

Exemples de menaces :

- **Fuite de secrets** : code ou identifiants envoyés à une API externe.
- **Prompt injection** : manipulation du modèle par un utilisateur malveillant.
- **Dépendance externe** : indisponibilité ou vulnérabilité du fournisseur de LLM.

Bonne pratique : utiliser des proxys, filtrer les prompts et éviter d'envoyer des données sensibles.

Problématique centrale : l'IAG traite souvent des données sensibles ou personnelles.

- **RGPD** : droit à l'oubli, consentement, minimisation des données.
- **Localisation des données** : datacenters UE vs hors UE.
- **Solutions** :
 - anonymisation avant envoi,
 - hébergement de modèles open source en interne,
 - passage par un proxy d'entreprise.

Un enjeu majeur souvent sous-estimé dans l'usage de l'IAG.

- **Origine des données d'entraînement** : risque que le modèle régénère des contenus protégés (texte, code, images).
- **Droits sur les contenus générés** :
 - Dans l'UE, pas de droit d'auteur automatique sur une production 100% IA.
 - L'entreprise doit définir une politique claire (contrats, licences internes).
- **Licences et open source** : vérifier la licence des modèles (Apache 2.0, MIT, restrictions) et des datasets utilisés.
- **Bonnes pratiques** :
 - tracer les sources de données et les outputs,
 - sensibiliser les équipes aux risques de réutilisation non conforme,
 - éviter d'intégrer sans vérification un contenu généré dans des livrables contractuels.

Constat : les modèles reflètent les biais de leurs données d'entraînement.

- Risque de stéréotypes et de discriminations dans les réponses.
- Impact fort dans les domaines sensibles (recrutement, médical, juridique).
- Besoin d'auditer les modèles dans leur contexte métier.

Message clé : l'évaluation humaine reste indispensable pour corriger les biais.

Questions clés :

- Qui est responsable si une IA génère du code erroné ou trompeur ?
- Comment tracer et auditer les décisions de l'IA ?

Bonnes pratiques :

- Supervision humaine obligatoire pour les tâches critiques.
- Mise en place d'une charte d'usage de l'IA.
- Définition de rôles et responsabilités clairs.

Impact énergétique :

- Fine-tuning complet = forte consommation GPU et empreinte carbone.
- LoRA/PEFT = alternatives plus sobres, adaptées aux entreprises.

Coûts cachés :

- Facturation à l'usage (tokens, appels API).
- Dépendance à un fournisseur unique.

Message clé : arbitrer entre innovation, budget et responsabilité environnementale.

Conclusion et bonnes pratiques

Synthèse :

- Les enjeux de sécurité, confidentialité et éthique sont incontournables.
- La gouvernance doit accompagner toute intégration de l'IA.
- Commencer petit, superviser, documenter et auditer.

Bonne pratique : intégrer les aspects éthiques dès la conception des projets IA.

Merci de votre attention

redha.moulla@axia-conseil.com